

# 当技术文档的读者变成 Agent

面向开发任务的技术知识生态 AI 可用性审计

中文论文初稿 v0.1

证据截止：2026-06-11；写作日期：2026-09-04

研究类型：基于可追溯检索记录的任务级案例审计

证据范围：CANN 与 CUDA 的 26 组结果目标匹配开发任务；单一具备网页检索与网页读取能力的 Agent；不包含、也不声称包含开发者用户研究、真实算卡运行或硬件性能比较。

## 摘要

生成式 AI 正在成为开发者获取技术知识、解释报错和组织实施步骤的入口。对于版本敏感、生态特有的开发任务，AI 回答的可用性不只取决于模型本身，还取决于技术知识能否被发现、读取、解释、交叉核验并转化为带前置条件的行动。然而，现有评估常将最终答案正确性、网页面向人类的可用性或单一检索命中率作为主要对象，因而难以区分失败究竟源于检索路径、页面工程、版本治理、社区供给还是模型先验不足。

本文提出技术知识生态的 AI 可用性（AI usability of technical knowledge ecosystems）：一个具备检索能力的 Agent 面对具体开发目标时，能否以可追溯、版本可判定、可执行的证据形成答案，以及为此付出的检索成本。我们以 CANN 与 CUDA 为案例，对 26 个结果目标相近的开发任务进行成对审计，覆盖环境与安装、算子开发、训练、推理与部署、性能优化、调试和迁移。对于每一对问题，研究按统一协议记录官方与第三方来源、网页读取结果、版本线索、模型自带知识、检索过程和答案产出；并以 11 项指标衡量官方可发现性、可抓取性、正文详尽度、版本清晰度、第三方支撑、模型自带知识、检索成本、版本可锁定性、步骤可复现性与综合置信度。综合置信度采用三源噪声-OR 公式，避免把“任一可靠渠道已足以支撑回答”的情形误判为平均分不足。

结果显示，AI 可用性是任务条件的属性，而不是一个站点的常数。CUDA 的 26 个任务均处于高置信度区间（均值 .920）；CANN 的均值为 .736，呈现 7 个高、16 个中高、2 个中和 1 个低的任务分布。CANN 的主要问题并非“全站无法读取”：26 个任务中仅自定义算子开发的核心 how-to 缺少可抓取正文或镜像兜底。更广泛的结构限制是版本树分散、第三

方知识的有效冗余不足，以及在专有、快速演进任务上的模型先验薄弱。进一步分析表明，最弱任务并不只由“技术深度”决定，而更受对生态专有知识和专有案例的依赖程度影响；调试类别的两栈差距最大（.287），自定义算子开发是 CANN 中唯一低置信度任务（.410）。

本文贡献包括：（1）给出面向可检索 Agent 的技术知识生态 AI 可用性定义和 11 指标测量框架；（2）提供 26 组任务级、来源可追溯的 CANN/CUDA 审计案例和可复算的评分管线；（3）识别“可见不等于可读”“可读不等于够用”“单一官方渠道不等于可用知识生态”等任务级失败模式；（4）提出面向 Agent 的文档、版本和社区知识基础设施设计建议。本文不将单一 Agent 的审计外推为所有模型能力，也不将分数解释为硬件、产品或人类开发者体验的总体排名。

关键词：AI 可用性；技术知识生态；检索增强 Agent；开发者文档；版本治理；开发者社区；CANN；CUDA

# 1. 引言

开发者面对陌生 API、工具链版本冲突、编译错误或性能问题时，长期依赖搜索、官方文档、代码仓、问答社区与本机试验来推进工作。AI Coding 工具改变了这条路径：开发者可以将目标或报错交给能够检索网页、读取仓库、综合资料并起草命令或代码的 Agent。由此，技术文档不再只由人类读者直接消费；它还是 Agent 形成建议时必须取得和判断的证据。

这种变化引出一个常被混用、但需要单独测量的问题：当一个会检索的 AI Agent 回答特定技术生态中的开发任务时，知识从哪里来，哪些环节决定它是否能给出可信、可执行的答案？这不是模型基准问题。一个回答失败，可能是模型缺少先验知识，也可能是官方页面只能在浏览器渲染、关键正文未被读取、版本信息相互冲突、社区资料无法互证，或检索成本迫使 Agent 在错误的来源上过早停止。反之，一份高质量回答也可能主要由稳定的第三方教程或模型先验支撑，而不是官方入口本身。

现有对代码生成工具的可用性研究主要考察开发者如何理解、采纳和校验生成结果 [1,2]；Agent 研究则讨论推理、工具使用与迭代的工作循环 [3,4]。这些工作十分重要，但若不拆开 Agent 所依赖的外部知识条件，便难以为文档站、社区和工具链治理提出可操作的改进。传统网站可用性评价同样不足：一个页面对人类浏览器可见，不能证明 Agent 能取得它的正文；一段抓到的正文，也不证明其中有能锁定版本、照着执行的内容。

本文将这类供给侧条件称为技术知识生态的 AI 可用性。它指：面对一个明确的开发目标，一个具备实时检索与网页读取能力的 Agent 能否从官方资料、第三方社区和模型自带知识中取得足够可靠的证据，形成版本可判定、步骤可执行的回答，并以多低的检索成本完成这一过程。该定义强调“技术知识生态”而非单个网页，也强调“任务”而非抽象站点评分。

我们以 CANN 与 CUDA 为案例开展 26 组任务级审计。两者服务于可比较的计算开发目标，但文档结构、版本体系、术语和社区规模不同。比较的单位不是 API 是否相同，更不是硬件性能；而是开发者要实现的结果目标是否相近，例如安装工具链、将模型转换为部署产物、定位内存越界、集成自定义算子或配置分布式训练。每个结果目标被编写成一对使用各自真实术语的问题，并按同一检索、取证和打分协议执行。

本文回答四个研究问题：

- RQ1：如何将技术知识生态的 AI 可用性分解为可独立观察、可量化并能定位失败点的指标？
- RQ2：在 26 个结果目标匹配的开发任务中，CANN 与 CUDA 的 AI 可用性呈现怎样的任务级分布？
- RQ3：哪些知识供给条件最常导致 Agent 的证据链断裂、版本不确定或步骤不可执行？
- RQ4：如何根据任务影响范围和反事实收益，为面向 Agent 的文档、版本和社区建设排序？

本文的贡献是：

1. 提出以“可追溯证据如何被搬进答案”为核心的 AI 可用性定义，并将其操作化为 11 项指标与可复算综合公式；
2. 提供 26 个跨栈任务对、52 次审计单元及其检索日志、原始观测和评分程序；
3. 给出任务级而非站点级的实证发现，收窄了“SPA 全站不可用”等过度概括，并识别了版本治理、有效二手冗余和专有知识依赖的结构性作用；
4. 提出将技术文档建设为“人类读者与 Agent 都可行动”的知识基础设施的设计建议。

---

## 2. 相关研究与概念定位

### 2.1 生成式 AI 的开发者使用与校验

代码生成工具并非简单替代开发者。已有研究表明，开发者会把生成结果作为草稿、对话伙伴、搜索捷径或快速试验的起点，同时通过阅读 diff、运行测试、查阅外部资料 and 限制权限来管理风险 [1,2]。本文不对开发者行为作新的经验性主张；它关注这些行为发生之前的一个供给侧前提：Agent 究竟能否获得支撑建议的外部技术证据。

### 2.2 Agent 的检索—行动循环

与一次性补全不同，Agent 可以交织任务理解、检索、网页或文件读取、候选行动、工具调用和反馈修订 [3,4]。在本文中，这一循环不是对模型内部认知过程的解释，而是一个可观察的工作结构：每个答案都可能由官方材料、第三方材料、模型先验或这些来源的组合支撑。研究因此不把“回答是否流畅”视为充分结果，而检查证据是否实际到达、是否足够具体、是否与版本和步骤相容。

### 2.3 从门户可用性到知识生态可用性

开发者门户、文档、样例、版本矩阵、仓库、论坛和第三方文章共同构成技术知识生态。传统门户评价主要关心人类用户的导航、理解和任务效率；本研究对象不同：一个具备网页检索和读取能力的 Agent 是否能发现、抓取、解释和行动化这些资源。二者相关但不能互相替代。页面视觉清晰不等于正文可被读取；SEO 命中不等于参数、版本和错误处理信息足以支持执行。

## 3. 研究设计

### 3.1 审计对象与比较边界

研究以一个具备网页搜索与网页读取能力的 Agent 为测量视角。每个审计单元由“任务 × 技术生态”构成，共 26 个任务、52 个单元。任务覆盖七类工作流：环境与安装、算子开发、训练、推理与部署、性能优化、调试和迁移；并服务于四类开发者角色：应用开发者、模型/框架迁移工程师、算子开发者和系统调优/生态贡献者。

每个任务在 CUDA 和 CANN 中均采用目标相近、但术语与实施路径符合各自生态的问题。例如：

- 模型转换：PyTorch → ONNX → TensorRT 与 ONNX → ATC → `.om`；
- 性能定位：Nsight Systems 与 `msprof` / Ascend PyTorch Profiler；
- 自定义算子：CUDA kernel + extension 与 Ascend C + `msOpGen` + `aclnn`；
- 分布式训练：NCCL 与 HCCL；
- 内存越界定位：Compute Sanitizer 与 `msSanitizer`。

研究不要求两边 API 形式完全相同，也不比较性能、运行时长、硬件成本或真实项目完成率。它比较的是：面向相近结果目标时，Agent 获得可执行技术知识的条件。

### 3.2 统一检索与取证协议

每个任务按同一流程执行：

1. 明确开发者结果目标，并以两栈真实术语写成问题对；
2. 用目标、技术栈和关键工具词进行网页检索，记录命中顺序、检索轮次和是否必须改写查询；
3. 优先读取官方资料，并记录正文是否完整取得、部分取得、仅有导航/摘要，或被 robots/渲染方式阻断；
4. 在官方证据不足时检索第三方来源，区分官方仓/官方论坛与真正独立的社区来源；
5. 记录可识别的版本、前置条件、命令、代码、参数表、错误说明和验证步骤；
6. 按预定义函数将原始观测映射到 1 – 5 分，生成综合置信度，并保留日志、来源和原始字段供复核。

26 个任务分四批完成。原始过程在 `task_run_log.md`，字段与量化函数在 `score_metrics.py`，可视化矩阵、方法说明与发现汇总分别位于 `17_official_site_focus.html`、`18_metric_definition.html`、`19_findings_ux_synthesis.html`。所有结论均应能回指任务、来源、原始观测或公式；无法读取的正文标记为“受阻”，而不以推断补成低分。

### 3.3 指标体系：三源、两关、四类结果

指标体系从“把知识搬进答案”的链路推导，而不是从网页功能清单拼接。知识有三个渠道：官方一手、第三方社区、模型自带知识。对前两类渠道分别考察触达和质量；再加入跨渠道成本、答案产出与综合汇总，形成 11 项指标（表 1）。

| 层面   | 指标          | 所问问题                           |
|------|-------------|--------------------------------|
| 官方触达 | ① 官方可发现性    | 官方资料能否在合理轮次内被找到？               |
| 官方触达 | ② 官方可抓取性    | Agent 能否取得核心正文，而不是只看到导航或摘要？    |
| 官方质量 | ③ 官方正文详尽度   | 是否含关键命令、代码、参数表、步骤或完整参考？        |
| 官方质量 | ④ 版本清晰度     | 是否存在 canonical 版本、明确适用范围与配套关系？ |
| 二手触达 | ⑤ 二手丰富度     | 是否存在足量、可发现的真正独立来源？             |
| 二手质量 | ⑥ 二手可信度/一致性 | 来源是否权威、够新、彼此独立并能相互验证？          |
| 模型先验 | ⑦ 模型自带知识    | 在不检索或检索受阻时，模型是否有足够稳定的基础覆盖？     |
| 过程   | ⑧ 检索成本      | 搜索、抓取、失败重试与改写查询带来的摩擦有多高？       |
| 产出   | ⑨ 版本可锁定性    | 最终回答能否确定到具体版本或兼容组合？            |
| 产出   | ⑩ 步骤可复现性    | 回答是否给出可照做或只需少量替换的步骤？           |
| 汇总   | ⑪ 综合置信度     | 在已取得证据下，答案可被可靠行动化的程度如何？        |

指标 ① – ⑥和⑧由可追溯原始观测经函数计算；⑦包含训练覆盖密度的半主观判断，同时以技术迭代节奏加入知识截止风险惩罚；⑨和⑩为产出侧因变量，不重复进入综合公式。特别地，“找得到”“抓得到”和“抓到的内容够不够用”被拆为三个指标，以避免把三种不同失败混为一类。

### 3.4 综合置信度与评分规则

综合置信度不使用简单平均。对技术问答而言，一条可靠渠道可能已经足以支撑回答；相反，多个薄弱渠道也不能因均值而被误判为可用。因而我们以归一化后的指标计算三源噪声-OR：

```
OFF = nm(①) × nm(②) × nm(③)
SEC = nm(⑤) × nm(⑥)
OWN = nm(⑦)
K    = 1 - (1 - OFF)(1 - SEC)(1 - OWN)

综合置信度 = K × [0.7 + 0.3 × nm(④)] × [0.9 + 0.1 × nm(⑧)]
```

其中  $nm(v)=v/5$ 。官方、第三方和模型先验任一渠道能稳定支撑答案时，**K** 会提高；版本不清和高检索成本则作为跨渠道折扣。若某渠道的核心正文受阻，渠道贡献按 0 计算，但“正文详尽度”仍保留为“受阻/无法实测”的中性状态，而不是伪造为 1 分。综合分的档位为：高（ $\geq .80$ ）、中高（ $\geq .63$ ）、中（ $\geq .45$ ）、低（ $\geq .24$ ）和很低（ $< .24$ ）。

该公式的目的不是制造一个“生态总分”，而是让每个任务都能追问：哪一个渠道没有送达？版本和成本各造成了多少折扣？为什么同样的页面读取失败在另一个任务中未必导致回答失败？

### 3.5 可复算性与质量控制

评分脚本为 `score_metrics.py`，每个指标均有 `score_N()` 函数；运行 `python3 score_metrics.py --json` 可重新生成  $26 \times 2$  的矩阵。二手来源按预定义类型锚定可信度，并加入时效与独立性惩罚：多篇内容若集中在同一平台或互相转述，不因“数量”而被视为独立互证。版本敏感度被保留为任务属性，不放入矩阵列，因为同一结果目标在两栈中通常同样敏感，不能帮助区分知识条件。

---

## 4. 结果

### 4.1 总体分布：差异存在于任务中，而不是抽象站点上

CUDA 侧 26 个任务的综合置信度均为高，范围为 .835 – 1.000，均值 .920。CANN 侧范围为 .410 – .901，均值 .736：7 个高、16 个中高、2 个中、1 个低。这个分布首先否定了两个简单叙事：它既不支持“CANN 文档整体不可用”，也不支持“只要能搜到官方页，AI 就能稳定回答”。

2 26 个结果目标匹配任务的 AI 可用性矩阵

任务各有 CUDA 与 CANN 两个审计单元；①—⑦、⑨—⑩为 1—5 分，⑧为实际检索成本，⑪为三源噪声—OR 综合置信度。

|          |                     |      | 官方知识        |             |               |              | 补充知识         |               |              | 行动条件        |              |              | 汇总        |
|----------|---------------------|------|-------------|-------------|---------------|--------------|--------------|---------------|--------------|-------------|--------------|--------------|-----------|
| 工作流      | 结果目标                | 生态   | 可发现<br>官方命中 | 可抓取<br>页面正文 | 正文详尽<br>命令/参数 | 版本清晰<br>版本关系 | 二手数量<br>独立来源 | 二手可信<br>质量/互证 | 模型先验<br>知识覆盖 | 检索成本<br>少为好 | 版本可锁<br>适用组合 | 可复现<br>步骤可执行 | 综合<br>置信度 |
| 环境与安装    | 版本兼容排查              | CUDA | 3           | 5           | 5             | 4            | 2            | 4             | 4            | 2搜·2抓       | 5            | 5            | 高         |
|          |                     | 3    | 4           | 4           | 4             | 3            | 4            | 2             | 2搜·2抓        | 5           | 5            | 中高           |           |
|          | 安装与环境变量             | CUDA | 4           | 5           | 5             | 3            | 3            | 4             | 5            | 1搜·1抓       | 4            | 5            | 高         |
|          |                     | 5    | 4           | 5           | 2             | 3            | 4            | 4             | 1搜·1抓        | 4           | 5            | 高            |           |
|          | 容器 / 镜像搭建           | CUDA | 5           | 5           | 4             | 5            | 3            | 4             | 5            | 1搜·2抓       | 4            | 5            | 高         |
| 算子开发     |                     | 5    | 5           | 5           | 4             | 2            | 2            | 3             | 1搜·4抓x       | 4           | 5            | 高            |           |
|          | 自定义算子开发             | CUDA | 5           | 5           | 5             | 3            | 4            | 4             | 5            | 1搜          | 5            | 5            | 高         |
|          |                     | 2    | 2           | 受阻          | 2             | 3            | 2            | 2             | 2搜x          | 2           | 3            | 低            |           |
|          | 算子精度排查              | CUDA | 2           | 5           | 5             | 5            | 2            | 4             | 4            | 2搜·2抓x      | 4            | 4            | 高         |
|          |                     | 2    | 4           | 5           | 2             | 3            | 4            | 3             | 2搜·1抓        | 3           | 4            | 中高           |           |
|          | 动态 shape / Tiling   | CUDA | 5           | 5           | 5             | 4            | 2            | 4             | 5            | 1搜·1抓       | 4            | 5            | 高         |
|          |                     | 2    | 4           | 4           | 4             | 2            | 4            | 2             | 2搜·2抓        | 4           | 4            | 中            |           |
|          | 算子融合                | CUDA | 2           | 5           | 4             | 5            | 2            | 4             | 4            | 2搜·3抓x      | 4            | 4            | 高         |
|          |                     | 5    | 4           | 5           | 2             | 2            | 3            | 2             | 1搜·1抓        | 4           | 4            | 中高           |           |
| 3 训练     | 注册与框架集成             | CUDA | 5           | 5           | 5             | 3            | 2            | 4             | 5            | 1搜·4抓       | 4            | 5            | 高         |
|          |                     | 2    | 4           | 5           | 3             | 5            | 3            | 3             | 2搜·4抓x       | 4           | 5            | 中高           |           |
|          | 算子库选型               | CUDA | 5           | 5           | 5             | 5            | 5            | 4             | 5            | 0-1         | 5            | 5            | 高         |
|          |                     | 4    | 4           | 3           | 3             | 3            | 4            | 3             | 1搜           | 4           | 4            | 中高           |           |
|          | 分布式训练配置             | CUDA | 5           | 5           | 5             | 3            | 3            | 4             | 4            | 1搜·1抓       | 4            | 5            | 高         |
|          |                     | 4    | 4           | 4           | 2             | 3            | 3            | 3             | 1搜·1抓        | 3           | 3            | 中高           |           |
|          | 混合精度训练              | CUDA | 5           | 5           | 5             | 5            | 3            | 4             | 5            | 1搜·3抓       | 5            | 5            | 高         |
| 推理与部署    |                     | 3    | 4           | 4           | 4             | 3            | 4            | 4             | 2搜·5抓        | 4           | 4            | 高            |           |
|          | 显存 / OOM 优化         | CUDA | 5           | 5           | 5             | 5            | 3            | 4             | 5            | 1搜·2抓x      | 4            | 5            | 高         |
|          |                     | 5    | 4           | 5           | 4             | 3            | 4            | 3             | 1搜·4抓        | 3           | 4            | 高            |           |
|          | 精度 / 收敛排查           | CUDA | 3           | 5           | 4             | 5            | 3            | 3             | 5            | 2搜·1抓       | 4            | 4            | 高         |
|          |                     | 3    | 4           | 5           | 3             | 3            | 4            | 3             | 2搜·3抓        | 3           | 4            | 中高           |           |
|          | 模型转换 / 导出           | CUDA | 5           | 5           | 5             | 4            | 4            | 4             | 4            | 1搜          | 5            | 5            | 高         |
| 性能优化     |                     | 4    | 4           | 4           | 2             | 4            | 4            | 3             | 1搜·3抓        | 3           | 4            | 中高           |           |
|          | 推理服务部署              | CUDA | 5           | 5           | 5             | 4            | 3            | 4             | 4            | 1搜·1抓       | 4            | 5            | 高         |
|          |                     | 5    | 4           | 4           | 3             | 2            | 4            | 2             | 1搜·3抓        | 4           | 4            | 中高           |           |
|          | 量化                  | CUDA | 5           | 5           | 5             | 3            | 3            | 4             | 4            | 1搜          | 4            | 5            | 高         |
|          |                     | 3    | 4           | 3           | 2             | 4            | 3            | 3             | 2搜·1抓        | 4           | 5            | 中高           |           |
|          | 动态 batch / shape 推理 | CUDA | 3           | 5           | 5             | 5            | 2            | 4             | 5            | 2搜·4抓x      | 5            | 5            | 高         |
| 6 调试     |                     | 3    | 4           | 5           | 2             | 3            | 5            | 3             | 2搜·2抓        | 4           | 4            | 中高           |           |
|          | Profiling 定位瓶颈      | CUDA | 4           | 5           | 5             | 4            | 4            | 4             | 4            | 1搜          | 4            | 5            | 高         |
|          |                     | 4    | 4           | 4           | 2             | 3            | 3            | 3             | 1搜·2抓        | 3           | 3            | 中高           |           |
|          | 访存 / occupancy 优化   | CUDA | 5           | 5           | 5             | 5            | 3            | 4             | 5            | 1搜·1抓       | 4            | 4            | 高         |
|          |                     | 4    | 4           | 4           | 5             | 3            | 4            | 3             | 1搜·3抓        | 4           | 4            | 高            |           |
|          | 计算与传输重叠             | CUDA | 5           | 5           | 5             | 5            | 3            | 4             | 5            | 1搜·2抓       | 5            | 5            | 高         |
| 7 迁移     |                     | 4    | 4           | 4           | 2             | 3            | 4            | 3             | 1搜·3抓        | 4           | 4            | 中高           |           |
|          | 多卡通信优化              | CUDA | 5           | 5           | 4             | 4            | 3            | 4             | 4            | 1搜·1抓       | 5            | 5            | 高         |
|          |                     | 2    | 4           | 3           | 3             | 3            | 4            | 3             | 2搜·2抓        | 4           | 4            | 中高           |           |
|          | 内存越界定位              | CUDA | 5           | 5           | 5             | 3            | 3            | 4             | 4            | 1搜·1抓       | 4            | 5            | 高         |
|          |                     | 5    | 4           | 5           | 2             | 2            | 4            | 2             | 1搜·2抓        | 4           | 5            | 中高           |           |
| 7 迁移     | 报错码 / 异常排查          | CUDA | 4           | 5           | 5             | 5            | 4            | 4             | 4            | 1搜·1抓       | 4            | 5            | 高         |
|          |                     | 3    | 4           | 2           | 2             | 3            | 3            | 2             | 2搜·1抓        | 3           | 3            | 中            |           |
|          | CUDA → 昇腾 迁移        | CUDA | 5           | 5           | 5             | 3            | 3            | 4             | 4            | 1搜          | 4            | 5            | 高         |
|          |                     | 4    | 4           | 4           | 4             | 3            | 4            | 3             | 1搜·1抓        | 4           | 4            | 高            |           |
|          | 跨芯片迁移               | CUDA | 5           | 5           | 5             | 4            | 3            | 4             | 5            | 1搜·2抓       | 5            | 5            | 高         |
| 概念心智模型对照 |                     | 2    | 4           | 4           | 3             | 3            | 4            | 3             | 2搜·4抓x       | 4           | 4            | 中高           |           |
|          |                     | CUDA | 5           | 5           | 4             | 5            | 3            | 4             | 5            | 1搜·4抓x      | 2            | 2            | 高         |
|          |                     | 5    | 4           | 5           | 5             | 3            | 4            | 4             | 1搜·3抓x       | 2           | 2            | 高            |           |

5 4 3 2 1 受阻 颜色表示指标档位：“受阻”表示核心正文无法读取，不能等同于低分。

来源：本研究 52 个审计单元的原始检索记录与可复算评分；交互版矩阵保留逐单元证据与来源细节。

26 个结果目标匹配任务的 AI 可用性矩阵。 矩阵将结果回溯至每个“任务 × 技术生态”单元，而非呈现单一生态总分。单元格“受阻”表示未能被读取，需与低档分值区分；完整的来源、原始观察与逐单元说明保留在可复现补充材料中。

表 2 列出各类工作流的均值。迁移、环境与安装、训练属于 CANN 的较强区域；算子开发和调试较弱，其中调试既是 CANN 绝对值最低的一类，也是两栈差距最大的一类。

| workflow | CANN 均值 | CUDA 均值 | 差距   | 任务数 |
|----------|---------|---------|------|-----|
| 迁移       | .810    | .907    | .097 | 3   |
| 环境与安装    | .799    | .904    | .105 | 3   |
| 训练       | .791    | .945    | .154 | 4   |
| 性能优化     | .752    | .957    | .204 | 4   |
| 推理与部署    | .723    | .920    | .197 | 4   |
| 算子开发     | .660    | .891    | .230 | 6   |
| 调试       | .646    | .933    | .287 | 2   |

因此，AI 可用性不是“某生态是否更适合 AI”的单一常数。一个生态可能在迁移入口把资料、工具与第三方实践组织得很厚，同时在报错、算子或版本专有任务上缺少足够的证据链。对于 Agent 产品而言，这意味着不能按域名简单决定信任策略；对于文档负责人而言，也意味着平均分不能替代对任务深谷的治理。

## 4.2 可抓取性并非平台常量：四种证据到达状态

早期观察曾把部分 CANN 文档的 SPA 视为系统性短板。26 个任务全量审计后，这一结论需要收窄。绝大多数主路径页面可通过 SSR、静态子树或镜像得到正文：`quickstart` 中的模型转换、面向 PyTorch 的 profiler、Tiling 正文、通信和最佳实践子树均提供了可用内容。唯一没有可抓取核心 how-to 或可靠镜像兜底的任务是 D（Ascend C 自定义算子开发），其核心 `opdevg` 引导链路的正文未能被 Agent 取得。

这不是“SPA 无关紧要”。D 恰好同时具有较弱第三方支撑和薄弱模型先验，因而三条知识渠道都未能兜底，综合分降至 .410，是唯一低档任务。相反，A（模型转换）和 B（性能定位）虽有深层参考页受限，但主路径 how-to 位于可抓取子树，仍能支撑中高置信度回答。

基于这一对照，证据到达不宜二分为“能抓/不能抓”，而应区分四态：

- 1. 完整可抓：正文、命令和参数可直接得到；CUDA 侧所有任务和 CANN 多数主路径属于此类；
- 2. 部分可抓且有镜像兜底：关键内容在替代入口可得，但链路并不直接，例如跨芯片迁移任务；
- 3. 可抓但内容泛化：页面存在且可读，却不能解释关键场景，例如 EZ9999 等错误码的通用兜底说明；
- 4. 核心正文受阻且无兜底：关键 how-to 不能取得，第三方和模型先验也不足以稳定补偿，例如自定义算子开发。

这一结果回答 RQ3 的一部分：可抓取性应按“任务所需的具体子树与正文”测量，不能根据站点技术栈或首页渲染方式整体赋值。

## 4.3 版本治理是覆盖面最广的折扣

CANN 的版本清晰度是最广泛的限制：26 个任务中有 12 个在指标④上为 2 分；取得 5 分的两个任务主要是版本无关的通讯任务。问题并不只是“版本很多”，而是同一内容散布在 8.0.RC2、80RC3alpha、82RC1alpha、商业版与社区版等并存树中，缺乏清晰的 canonical 指向；同时 CANN、驱动、PyTorch、torch\_npu 等往往需要跨多个页面拼接配套关系。

版本不清会对三条知识渠道同时施加折扣：官方文档即使正文充足，Agent 也难以确定它是否适用于当前组合；第三方文章可能引用旧版；模型先验则更容易在快速迭代的 API 上过时。反事实计算显示，若实现 canonical 版本入口和可查询的配套组合，并将④提升到 5，26 个 CANN 任务的平均综合置信度将提高 .104，16 个任务跨越档位。这是所有供给侧改进中覆盖面最大的项目。

## 4.4 有内容不等于有冗余：第三方与模型先验的双薄弱

当官方资料不足时，第三方和模型先验是 Agent 的两条绕行通道。CANN 的有效二手来源常为 2–3 条，且集中于 CSDN、华为云论坛等少数平台；部分任务还出现同平台多文互相转述的情况。知乎等平台的反爬会进一步缩小“人眼看到的社区”与“Agent 实际能读取的社区”之间的交集。相比之下，CUDA 任务更常拥有 Stack Overflow、独立博客、课程和代码仓等多平台互证。

模型自带知识的差异会放大这一问题。CANN 在 26 个任务上的模型先验均值约为 2.85，CUDA 无任务低于 4。对于成熟 CUDA 工具，检索常用于核对细节；对于快速变化且专有的 CANN 工具链，检索通常是形成答案的主要甚至唯一来源。于是，一旦官方正文、版本信息或二手社区中任一环节断裂，Agent 便更容易以类比外推填补空白。本文不把这种风险称为“模型幻觉率”，因为本研究没有测量模型内部真实性；它测量的是答案缺乏可追溯外部证据时的知识条件。

X（内存越界定位）说明了“官方正文很强仍可能不够”。该任务的 msSanitizer 官方正文详尽度为 5，但独立二手来源仅一条、模型先验为 2，因此总体仍处于中高而非高。对 Agent 而言，生态的可用性取决于是否存在可替代、可核验的证据网络，而不是单一官方页面的质量。

## 4.5 深度只是表象，专有知识依赖才是更接近的机制

若按开发流程深度分组，CANN 的均值从上手/环境侧 .77、训练/日常侧 .74 到算子/深处自研侧 .70，呈单调下降。但这不是充分解释。深层任务 U（访存/occupancy 优化）取得 .88，因为其最佳实践子树充足，且缓存与访存原理能从 CUDA 的通讯心智模型迁移；反过来，较浅的 E（错误码排查）仅为 .55，因为它依赖专有错误码案例，官方页面内容泛化，第三方与模型先验也不足。

因此，更接近的解释不是“任务越深，文档越差”，而是任务对生态专有知识、专有版本关系和专有案例的依赖越高，Agent 越缺少可替代的知识通道。这一机制为文档投入提供了更精确的优先级：通讯性原理可以由已有模型知识和跨栈经验部分兜底；错误码、版本组合、算子实现和设备特性等专有知识则不能依赖类比外推。

## 4.6 反事实改进排序：抬均值与修深谷是两本账

研究以当前原始分为基线，将不同供给侧改进的假设变化代回综合公式，得到表 3。它不是实际 A/B 测试，而是用于透明比较“若某一指标确实改善，哪些任务会受益”的反事实分析。

| 改进假设                    | 平均综合提升 | 跨档任务  | 最大单任务提升 | 主要影响         |
|-------------------------|--------|-------|---------|--------------|
| canonical 版本与配套查询器      | +.104  | 16/26 | +.18    | 全局版本清晰度      |
| 扶持独立二手生态                | +.056  | 7/26  | +.11    | 社区丰富度与互证     |
| 提供可被长期吸收的权威语料           | +.048  | 4/26  | +.11    | 模型先验（长期）     |
| 机器可读出口（如 Markdown/文本导出） | +.027  | 4/26  | +.11    | 正文可读取性       |
| 页面组织与可抓取规范              | +.013  | 1/26  | +.06    | 已可读页面的正文深度   |
| 自定义算子 how-to 静态化        | +.004  | 1/26  | +.11    | D: .41 → .52 |
| 错误码“一码一页”               | +.003  | 1/26  | +.09    | E: .55 → .64 |

“版本收口”在平均提升上断层领先，因为它影响广泛；但这不意味着只应做广覆盖项目。自定义算子 how-to 静态化和错误码细化只改变单个任务，均摊收益小，却分别修复了矩阵中唯一的低档任务和调试深谷。前者是普惠型投资，后者是最低体验救济；二者应使用不同的资源决策口径。

## 5. 讨论：面向 Agent 的知识基础设施

### 5.1 从“页面可见”转向“证据可行动”

面向 Agent 的文档不应被理解为把网页改成纯文本，而是让每个关键任务单元都能以明确证据被引用和执行。一个最低限度的证据单元应说明：任务目标、适用版本、前置条件、最小命令或代码、预期输出、常见失败、恢复路径和稳定 URL。这样做同时服务人类读者与 Agent：人能快速定位，Agent 能减少把片段拼成未经验证结论的需要。

### 5.2 版本关系应成为可查询的产品能力

版本号不应只是页面标题或 URL 片段。对于工具链生态，版本关系本身是一个需要被查询和验证的对象。可执行的做法包括：提供 canonical 当前版本和统一历史归档；在每页标注适用版本与最后验证时间；发布驱动、工具链、框架和插件之间的机器可读兼容矩阵；允许开发者或 Agent 用最小环境 manifest 查询唯一或有限的合法组合。否则，文档越多，Agent 与开发者越可能从不同版本树中取到互不兼容的片段。

### 5.3 将社区视作冗余网络，而非流量附属品

第三方内容的价值不只在于数量。对于 Agent，它承担官方证据不可达、过于概括或版本不匹配时的绕行与互证功能。因此，社区治理需要关注可访问性、独立性和可归因性：高质量样例、公开 issue、带版本的复盘、可索引的错误码讨论和不同平台的独立解释，比同平台内大量重复转载更能提高知识生态的韧性。

### 5.4 Agent 产品应暴露证据和未知，而非隐藏不确定性

当任务依赖专有版本、硬件拓扑或私有工程事实时，理想的 Agent 行为不是生成看似完整的答案，而是明确说明：哪些步骤已有来源支撑，哪些内容来自类比或旧知识，尚需用户提供什么事实，以及下一步最小验证是什么。本文的指标可以转化为 Agent 界面中的状态：来源已取得/部分取得/受阻，版本已锁定/待确认，步骤可直接执行/需要本机事实。这样，AI 可用性评估不只诊断内容生态，也能反向塑造更可控的 Agent 交互。

## 6. 局限与有效性边界

本研究有以下限制。

第一，研究使用单一 Agent 与特定检索、网页读取配置，不能代表所有模型、搜索引擎、企业知识库或未来版本的能力；其结论应理解为一个明确测量条件下的案例审计。第二，单任务单元主要来自一次完整检索运行，虽保留了过程和可重算字段，但无法给出跨时间、跨模型的方差估计。第三，指标⑦“模型自带知识”仍含半主观判断；研究以技术迭代节奏加入知识截止风险，却不能直接观测训练语料覆盖。第四，第三、四批有部分问题文本在事后补编，尽管原始观测和过程记录仍可回溯，措辞差异仍可能影响检索。第五，反事实 ROI 只说明在既定公式与假设下的潜在收益，不是站方真实用户行为、流量转化或改版效果的因果估计。

更重要的是，本文不测量人类开发者的主观体验、实际完成率、协作方式或硬件性能。它也不声称 CUDA 与 CANN 的任何永久总体排名。人类开发者体验、真实项目协同和环境运行结果需要用不同的研究设计独立测量，而不能从本审计分数直接推出。

## 7. 结论

当 AI Agent 成为技术知识的重要使用者时，文档与社区不再只是供人浏览的内容集合，而是影响答案能否被可靠行动化的知识基础设施。通过 26 组 CANN/CUDA 开发任务的可追溯审计，本文表明：AI 可用性需要在任务层面理解；“可见、可读、够用、可锁版本、可复现”是相互独立的条件；最广泛的限制来自版本治理与有效知识冗余，而非笼统的页面可抓取性；最危险的深谷出现在高专有知识依赖的算子和调试任务。

这一视角为技术社区提出了一个可操作的目标：不仅让页面被人类读到，更要让 Agent 能取得可引用、可验证、可执行的证据，并在证据不足时清楚地暴露未知。对文档、工具链和 Agent 产品而言，面向人和 AI 的知识基础设施将成为同一项设计任务的两个侧面。

---

## 参考文献（首轮书目；正式投稿前按目标期刊格式核验并补充）

1. Barke, S., James, M. B., & Polikarpova, N. (2023). \*Grounded Copilot: How Programmers Interact with Code-Generating Models\*. Proceedings of the ACM on Human-Computer Interaction, 7(CSCW1).
2. Vaithilingam, P., Zhang, T., & Glassman, E. L. (2022). \*Expectation vs. Experience: Evaluating the Usability of Code Generation Tools Powered by Large Language Models\*. Proceedings of the 2022 CHI Conference on Human Factors in Computing Systems.
3. Yao, S., Zhao, J., Yu, D., et al. (2023). \*ReAct: Synergizing Reasoning and Acting in Language Models\*. International Conference on Learning Representations.
4. Yang, J., Jimenez, C. E., Wettig, A., et al. (2024). \*SWE-agent: Agent-Computer Interfaces Enable Automated Software Engineering\*. Advances in Neural Information Processing Systems.

附录 A：26 个任务与 CANN 综合置信度

| 代号 | 任务                | CANN 综合置信度 |
|----|-------------------|------------|
| A  | 模型转换/导出           | .75        |
| B  | Profiling 定位瓶颈    | .70        |
| C  | 算子库选型             | .77        |
| D  | 自定义算子开发           | .41        |
| E  | 报错码/异常排查          | .55        |
| F  | 分布式训练配置           | .72        |
| G  | CUDA→昇腾迁移         | .84        |
| H  | 量化                | .69        |
| I  | 版本兼容排查            | .73        |
| J  | 安装与环境变量           | .80        |
| K  | 容器/镜像搭建           | .86        |
| L  | 算子精度排查            | .69        |
| M  | 动态 shape/Tiling   | .63        |
| N  | 算子融合              | .74        |
| O  | 注册与框架集成           | .72        |
| P  | 混合精度训练            | .83        |
| Q  | 显存/OOM 优化         | .86        |
| R  | 精度/收敛排查           | .75        |
| S  | 推理服务部署            | .74        |
| T  | 动态 batch/shape 推理 | .72        |
| U  | 访存/occupancy 优化   | .88        |
| V  | 计算与传输重叠           | .72        |
| W  | 多卡通信优化            | .70        |
| X  | 内存越界定位            | .74        |
|    |                   |            |

| 代号 | 任务       | CANN 综合置信度 |
|----|----------|------------|
| Y  | 跨芯片迁移    | .68        |
| Z  | 概念心智模型对照 | .90        |

## 附录 B：可追溯材料

- 任务级可视化矩阵：[17\\_official\\_site\\_focus.html](#)
- 指标定义、评分锚点和公式：[18\\_metric\\_definition.html](#)
- 发现、反事实 ROI 和局限：[19\\_findings\\_ux\\_synthesis.html](#)
- 原始检索过程：[task\\_run\\_log.md](#)
- 原始观测和重算脚本：[score\\_metrics.py](#)