


实验方法概览

任务与流程分析

沿开发 workflow 拆解任务
定位知识获取和指标位置



指标与评分规则

定义指标，明确评分标准
按可核验证据判分

知识节点	指标	1分	2分	3分	4分	5分
官方发现	M1 官方发现	在搜索引擎中未找到	在搜索引擎中找到	在搜索引擎中找到	在搜索引擎中找到	在搜索引擎中找到
第三方数据	M5 第三方数据	0分	1-2分	3-4分	5分	6分
正文数据	M2 正文数据	无可用数据	少量可用数据	较多可用数据	大量可用数据	全部可用数据
内容支持	M3 内容支持	无可用数据	少量可用数据	较多可用数据	大量可用数据	全部可用数据
数据支持	M4 数据支持	无可用数据	少量可用数据	较多可用数据	大量可用数据	全部可用数据
数据支持	M6 数据支持	无可用数据	少量可用数据	较多可用数据	大量可用数据	全部可用数据
数据支持	M7 数据支持	无可用数据	少量可用数据	较多可用数据	大量可用数据	全部可用数据
数据支持	M8 数据支持	无可用数据	少量可用数据	较多可用数据	大量可用数据	全部可用数据
数据支持	M9 数据支持	无可用数据	少量可用数据	较多可用数据	大量可用数据	全部可用数据
数据支持	M10 数据支持	无可用数据	少量可用数据	较多可用数据	大量可用数据	全部可用数据
数据支持	M11 数据支持	无可用数据	少量可用数据	较多可用数据	大量可用数据	全部可用数据

问题对与实验执行

同一任务分别设置两侧问题
三个模型按统一要求执行

CUDA

GPU 利用率不高，
怎样采集性能数据、
找到模型运行慢的原因？
工具：Nsight Systems
交付：采集命令 + 分析步骤

CANN

昇腾上运行 PyTorch，
怎样采集性能数据、
找到模型运行慢的原因？
工具：msprof / Ascend PyTorch Profiler
交付：代码 + 步骤

评分复核与方法沉淀

复核评分，比较结果
保存证据，复用实验方法

过程记录 process.jsonl

回答、搜索与资料读取

问句：昇腾上跑 PyTorch 想定位瓶颈，
怎么用 msprof / Ascend PyTorch
Profiler 采集分析？给出代码和步骤。


评分记录 evaluation.json

得分、依据与未满足项

M1 官方发现：5分
首次查询第1条即为相关官方来源

25组问题对 × 2个平台 × 3个模型 = 150次主实验

知识获取流程与指标定位



流程各环节对应的五档评分标准

流程环节	指标	1分	2分	3分	4分	5分
搜索 候选	M1 官方发现	预算用尽 仍未发现	第3查起 首次命中	第2查 首次命中	首查 第2—5条	首查 第1条
	M5 第三方数量	0条	1—2条	3—4条	5条	至少6条
读取 正文	M2 正文取得	无可识别 目标内容	仅标题/导航 或元数据	仅明确 摘要/摘录	直接正文 缺损有据	直接正文 完整边界有据
	M3 内容支撑	只有概述	仅零散细节	完整段落 仍缺关键内容	主流程完整 仍缺分支约束	原题所需 内容全齐
模型 先验	M7 检索前知识	无正确知识 或关键主张错	只有正确概念	正确方法片段 缺关键细节	完整正确流程 缺参数约束	原题知识要求 准确全覆盖
汇总 证据	M6 说法支持	关键矛盾 尚未解决	关键说法 无核对依据	部分说法有据 其余未核验	全部说法有据 缺独立互证	全部说法有据 且独立互证
	M8 调用成本	$C \geq 9$	$C = 7-8$	$C = 5-6$	$C = 3-4$	$C = 1-2$
检查 充分性	M4 版本关系	无版本信息	无选版依据 或冲突未解	部分关系明确 缺必要对应	合并官方约束 才可确定版本	官方表/规则 直接确定版本
	M9 回答定版	缺少所需 版本信息	有版本无依据 或关键矛盾	部分组件有据 其余未定版	全部有据范围 未全定具体版	全部有据具体版 无未解冲突
	M10 操作补改	仅目标描述 或示意	仅操作骨架 关键操作不明	有具体方案 需纠错或补充	指导完整 仅换已说明环境值	指导与前提齐 无需补写修正
终答	M11 综合支撑 连续0—100	$M11 = 100[1 - (1 - x_1x_2x_3)(1 - x_5x_6)(1 - x_7)](0.7 + 0.3x_4)(0.9 + 0.1x_8)$ $x_i = M_i / 5 \ (i = 1...8)$ ；系数预定；M9/M10独立报告；未经概率校准				

C=实际搜索+获取，失败计数；未知/受阻/N/A单列，不补零。M2完整性未知留4—5；M6高档须无未解矛盾。

用可核验的标准，让评分更客观、更一致


以 M7 模型自带知识为例

改前：模型自评

自评知识强弱，再作时效修正

- 5 覆盖密集，可答且大体可靠
- 4 流程熟悉，可给出骨架
- 3 有概念，细节 / 版本需检索
- 2 知识薄弱，不敢给命令
- 1 依赖现查，知识易过时

不足 知识强弱靠自评，正确性难核验



改后：回答核验

先保存无工具回答，再按证据核验

- 5 原题所需流程 / 解释 / 参数 / 约束均准确
- 4 流程 / 解释完整正确，参数 / 约束待补
- 3 方法 / 解释片段正确，关键细节待补
- 2 概念正确，无具体方法 / 解释
- 1 无可核验正确知识，或关键主张错

改进 依据可追溯，自信程度不计分

同一个开发目标，分别设置两侧问题

1 选开发任务

覆盖环境、开发、训练、部署、优化、调试、迁移等七类工作流

2 确定共同目标

3 写成两侧问题

找到模型运行慢的原因

CUDA



GPU 利用率不高，
怎样采集性能数据、
找到模型运行慢的原因？

工具：Nsight Systems

交付：采集命令 + 分析步骤

CANN



昇腾上运行 PyTorch，
怎样采集性能数据、
找到模型运行慢的原因？

工具：msprof / Ascend PyTorch Profiler

交付：代码 + 步骤

目标相近，工具和交付要求按各自平台设置

25组对照问题

三个模型执行，统一评分后分别汇总

25组问题 × 2个平台 × 3个模型 = 150次主实验

每次保存：无工具回答 · 资料来源 · 最终回答 · 调用次数

1 三个模型执行

 GLM-5.3

 DeepSeek

V4.1 Flash

 Kimi

kimi-k3-2

同一组问题、工具与额度

2 统一评分与复核

初评 GLM-5.3

辅助复核 GPT-5.6 Luna

审定 GPT-6 Astra

程序检查：原文 · 档位 · 计算
重点复核，修改留依据

3 看不同模型是否发现相同问题

CUDA

CANN

各模型内，按指标算两侧均分

GLM-5.3
对照结果

DeepSeek
对照结果

Kimi
对照结果

查看反复出现的薄弱环节

减少单一模型偏好的影响，找到共同的薄弱环节

把实验方法沉淀为可复用的 Benchmark Skill

可替换的输入

本次示例：性能分析任务

Benchmark Skill

任务

定位性能瓶颈

采集并分析性能数据

平台

CANN 昇腾

模型

GLM-5.3



准备实验

确定任务与实验要求



执行实验

先回答，再检索与作答



评分与复核

统一判分，回查证据



过程记录

process.jsonl

回答、搜索与资料读取

问句：昇腾上跑 PyTorch
想定位瓶颈，怎么用 msprof /
Ascend PyTorch Profiler
采集分析？给出代码和步骤。
检索：昇腾 PyTorch Profiler
性能分析 msprof 官方文档 hiascend
返回：msprof-analyze/README.md
-代码预览-MindStudio-Profiler ...



评分记录

evaluation.json

得分、依据与未满足项

M1 官方发现：5分
首次查询第1条即为相关官方来源
(gitcode.com/Ascend/
msprof-analyze, Ascend官方组织的
MindStudio Profiler仓库)，
第5条亦为hiascend.com官方文档，
首次查询即命中且排名第1。

可以复核

回查
原始记录

换任务、平台或模型，继续复用