


# 实验方法概览

## 任务与流程分析

沿开发 workflow 拆解任务  
定位知识获取和指标位置



## 指标与评分规则

定义指标，明确评分标准  
按可核验证据判分

| 知识节点 | 指标       | 1分        | 2分        | 3分        | 4分        | 5分        |
|------|----------|-----------|-----------|-----------|-----------|-----------|
| 背景知识 | M1 官方发现  | 在知识库中找到答案 | 在知识库中找到答案 | 在知识库中找到答案 | 在知识库中找到答案 | 在知识库中找到答案 |
| 背景知识 | M2 官方发现  | 在知识库中找到答案 | 在知识库中找到答案 | 在知识库中找到答案 | 在知识库中找到答案 | 在知识库中找到答案 |
| 背景知识 | M3 官方发现  | 在知识库中找到答案 | 在知识库中找到答案 | 在知识库中找到答案 | 在知识库中找到答案 | 在知识库中找到答案 |
| 背景知识 | M4 官方发现  | 在知识库中找到答案 | 在知识库中找到答案 | 在知识库中找到答案 | 在知识库中找到答案 | 在知识库中找到答案 |
| 背景知识 | M5 官方发现  | 在知识库中找到答案 | 在知识库中找到答案 | 在知识库中找到答案 | 在知识库中找到答案 | 在知识库中找到答案 |
| 背景知识 | M6 官方发现  | 在知识库中找到答案 | 在知识库中找到答案 | 在知识库中找到答案 | 在知识库中找到答案 | 在知识库中找到答案 |
| 背景知识 | M7 官方发现  | 在知识库中找到答案 | 在知识库中找到答案 | 在知识库中找到答案 | 在知识库中找到答案 | 在知识库中找到答案 |
| 背景知识 | M8 官方发现  | 在知识库中找到答案 | 在知识库中找到答案 | 在知识库中找到答案 | 在知识库中找到答案 | 在知识库中找到答案 |
| 背景知识 | M9 官方发现  | 在知识库中找到答案 | 在知识库中找到答案 | 在知识库中找到答案 | 在知识库中找到答案 | 在知识库中找到答案 |
| 背景知识 | M10 官方发现 | 在知识库中找到答案 | 在知识库中找到答案 | 在知识库中找到答案 | 在知识库中找到答案 | 在知识库中找到答案 |
| 背景知识 | M11 官方发现 | 在知识库中找到答案 | 在知识库中找到答案 | 在知识库中找到答案 | 在知识库中找到答案 | 在知识库中找到答案 |

## 问题对与实验执行

同一任务分别设置两侧问题  
按统一要求执行实验

**CUDA**

GPU 利用率不高，  
怎样采集性能数据、  
找到模型运行慢的原因？  
工具：Nsight Systems  
交付：采集命令 + 分析步骤

**CANN**

昇腾上运行 PyTorch，  
怎样采集性能数据、  
找到模型运行慢的原因？  
工具：msprof / Ascend PyTorch Profiler  
交付：代码 + 步骤

## 评分复核与方法沉淀

复核评分，比较结果  
保存证据，复用实验方法

**过程记录** process.jsonl

回答、搜索与资料读取


问句：昇腾上跑 PyTorch 想定位瓶颈，  
怎么用 msprof / Ascend PyTorch  
Profiler 采集分析？给出代码和步骤。

**评分记录** evaluation.json

得分、依据与未满足项

M1 官方发现：5分  
首次查询第1条即为相关官方来源

# 知识获取流程与指标定位



# 流程各环节对应的五档评分标准

| 流程环节      | 指标                  | 1分                                                                                                                                         | 2分              | 3分              | 4分               | 5分               |
|-----------|---------------------|--------------------------------------------------------------------------------------------------------------------------------------------|-----------------|-----------------|------------------|------------------|
| 搜索<br>候选  | M1 官方发现             | 预算用尽<br>仍未发现                                                                                                                               | 第3查起<br>首次命中    | 第2查<br>首次命中     | 首查<br>第2—5条      | 首查<br>第1条        |
|           | M5 第三方数量            | 0条                                                                                                                                         | 1—2条            | 3—4条            | 5条               | 至少6条             |
| 读取<br>正文  | M2 正文取得             | 无可识别<br>目标内容                                                                                                                               | 仅标题/导航<br>或元数据  | 仅明确<br>摘要/摘录    | 直接正文<br>缺损有据     | 直接正文<br>完整边界有据   |
|           | M3 内容支撑             | 只有概述                                                                                                                                       | 仅零散细节           | 完整段落<br>仍缺关键内容  | 主流程完整<br>仍缺分支约束  | 原题所需<br>内容全齐     |
| 模型<br>先验  | M7 检索前知识            | 无正确知识<br>或关键主张错                                                                                                                            | 只有正确概念          | 正确方法片段<br>缺关键细节 | 完整正确流程<br>缺参数约束  | 原题知识要求<br>准确全覆盖  |
| 汇总<br>证据  | M6 说法支持             | 关键矛盾<br>尚未解决                                                                                                                               | 关键说法<br>无核对依据   | 部分说法有据<br>其余未核验 | 全部说法有据<br>缺独立互证  | 全部说法有据<br>且独立互证  |
|           | M8 调用成本             | $C \geq 9$                                                                                                                                 | $C = 7-8$       | $C = 5-6$       | $C = 3-4$        | $C = 1-2$        |
| 检查<br>充分性 | M4 版本关系             | 无版本信息                                                                                                                                      | 无选版依据<br>或冲突未解  | 部分关系明确<br>缺必要对应 | 合并官方约束<br>才可确定版本 | 官方表/规则<br>直接确定版本 |
|           | M9 回答定版             | 缺少所需<br>版本信息                                                                                                                               | 有版本无依据<br>或关键矛盾 | 部分组件有据<br>其余未定版 | 全部有据范围<br>未全定具体版 | 全部有据具体版<br>无未解冲突 |
|           | M10 操作补改            | 仅目标描述<br>或示意                                                                                                                               | 仅操作骨架<br>关键操作不明 | 有具体方案<br>需纠错或补充 | 指导完整<br>仅换已说明环境值 | 指导与前提齐<br>无需补写修正 |
| 终答        | M11 综合支撑<br>连续0—100 | $M11 = 100[1 - (1 - x_1x_2x_3)(1 - x_5x_6)(1 - x_7)](0.7 + 0.3x_4)(0.9 + 0.1x_8)$<br>$x_i = M_i / 5 \ (i = 1...8)$ ；系数预定；M9/M10独立报告；未经概率校准 |                 |                 |                  |                  |

C=实际搜索+获取，失败计数；未知/受阻/N/A单列，不补零。M2完整性未知留4—5；M6高档须无未解矛盾。

# 用可核验的标准，让评分更客观、更一致


以 M7 模型自带知识为例

## 改前：模型自评

自评知识强弱，再作时效修正

- 5 覆盖密集，可答且大体可靠
- 4 流程熟悉，可给出骨架
- 3 有概念，细节 / 版本需检索
- 2 知识薄弱，不敢给命令
- 1 依赖现查，知识易过时

不足 知识强弱靠自评，正确性难核验



## 改后：回答核验

先保存无工具回答，再按证据核验

- 5 原题所需流程 / 解释 / 参数 / 约束均准确
- 4 流程 / 解释完整正确，参数 / 约束待补
- 3 方法 / 解释片段正确，关键细节待补
- 2 概念正确，无具体方法 / 解释
- 1 无可核验正确知识，或关键主张错

改进 依据可追溯，自信程度不计分

# 同一个开发目标，分别设置两侧问题

## 1 选开发任务

覆盖环境、开发、训练、部署、优化、调试、迁移等七类工作流

## 2 确定共同目标

## 3 写成两侧问题

### 找到模型运行慢的原因

#### CUDA



GPU 利用率不高，  
怎样采集性能数据、  
找到模型运行慢的原因？

工具：Nsight Systems

交付：采集命令 + 分析步骤

#### CANN



昇腾上运行 PyTorch，  
怎样采集性能数据、  
找到模型运行慢的原因？

工具：msprof / Ascend PyTorch Profiler

交付：代码 + 步骤

目标相近，工具和交付要求按各自平台设置

25组问题对

# 三个模型执行，统一评分后分别汇总

每次保存：无工具回答 · 资料来源 · 最终回答 · 调用次数

## 1 三个模型执行

 GLM-5.3

 DeepSeek  
V4.1 Flash

 Kimi  
kimi-k3-2

同一组问题、工具与额度

## 2 统一评分与复核

初评 GLM-5.3

辅助复核 GPT-5.6 Luna

审定 GPT-6 Astra

程序检查：原文 · 档位 · 计算  
重点复核，修改留依据

## 3 看不同模型是否发现相同问题

CUDA

CANN

各模型内，按指标算两侧均分

GLM-5.3  
对照结果

DeepSeek  
对照结果

Kimi  
对照结果

查看反复出现的薄弱环节

减少单一模型偏好的影响，找到共同的薄弱环节

# 把实验方法沉淀为可复用的 Benchmark Skill

## 任务

性能瓶颈定位、模型转换与部署  
版本配套排查等任务

## 平台

本次 CANN 昇腾 / CANN NVIDIA CUDA  
可扩展：华为云等平台

## 模型

GLM-5.3 DeepSeek Kimi  
也可配置其他模型



## 准备实验

选择输入，确定实验要求



## 执行实验

先回答，再检索与作答



## 评分与复核

统一判分，回查证据

## 换输入，继续复用

先明确对应任务与评分要求，  
再按同样流程开展评测。

本次记录示例

性能瓶颈定位  
CANN, GLM-5.3

## 过程记录

process.jsonl

回答、搜索与资料读取

问句：昇腾上跑 PyTorch  
想定位瓶颈，怎么用 msprof /  
Ascend PyTorch Profiler  
采集分析？给出代码和步骤。  
检索：昇腾 PyTorch Profiler  
性能分析 msprof 官方文档 hiascend  
返回：msprof-analyze/README.md  
-代码预览-MindStudio-Profiler ...

## 评分记录

evaluation.json

得分、依据与未满足项

M1 官方发现：5分  
首次查询第1条即为相关官方来源  
(gitcode.com/Ascend/  
msprof-analyze, Ascend官方组织的  
MindStudio Profiler仓库)，  
第5条亦为hiascend.com官方文档，  
首次查询即命中且排名第1。