


# 知识获取流程与指标定位



概念环节定位，实际评分独立执行。模型可能无法可靠识别知识缺口；证据不足时，终答须显式说明边界。

# 流程各环节对应的五档评分标准


| 流程环节      | 指标                  | 1分                                                                                                                                         | 2分              | 3分              | 4分               | 5分               |
|-----------|---------------------|--------------------------------------------------------------------------------------------------------------------------------------------|-----------------|-----------------|------------------|------------------|
| 搜索<br>候选  | M1 官方发现             | 预算用尽<br>仍未发现                                                                                                                               | 第3查起<br>首次命中    | 第2查<br>首次命中     | 首查<br>第2—5条      | 首查<br>第1条        |
|           | M5 第三方数量            | 0条                                                                                                                                         | 1—2条            | 3—4条            | 5条               | 至少6条             |
| 读取<br>正文  | M2 正文取得             | 无可识别<br>目标内容                                                                                                                               | 仅标题/导航<br>或元数据  | 仅明确<br>摘要/摘录    | 直接正文<br>缺损有据     | 直接正文<br>完整边界有据   |
|           | M3 内容支撑             | 只有概述                                                                                                                                       | 仅零散细节           | 完整段落<br>仍缺关键内容  | 主流程完整<br>仍缺分支约束  | 原题所需<br>内容全齐     |
| 模型<br>先验  | M7 检索前知识            | 无正确知识<br>或关键主张错                                                                                                                            | 只有正确概念          | 正确方法片段<br>缺关键细节 | 完整正确流程<br>缺参数约束  | 原题知识要求<br>准确全覆盖  |
| 汇总<br>证据  | M6 说法支持             | 关键矛盾<br>尚未解决                                                                                                                               | 关键说法<br>无核对依据   | 部分说法有据<br>其余未核验 | 全部说法有据<br>缺独立互证  | 全部说法有据<br>且独立互证  |
|           | M8 调用成本             | $C \geq 9$                                                                                                                                 | $C = 7-8$       | $C = 5-6$       | $C = 3-4$        | $C = 1-2$        |
| 检查<br>充分性 | M4 版本关系             | 无版本信息                                                                                                                                      | 无选版依据<br>或冲突未解  | 部分关系明确<br>缺必要对应 | 合并官方约束<br>才可确定版本 | 官方表/规则<br>直接确定版本 |
|           | M9 回答定版             | 缺少所需<br>版本信息                                                                                                                               | 有版本无依据<br>或关键矛盾 | 部分组件有据<br>其余未定版 | 全部有据范围<br>未全定具体版 | 全部有据具体版<br>无未解冲突 |
|           | M10 操作补改            | 仅目标描述<br>或示意                                                                                                                               | 仅操作骨架<br>关键操作不明 | 有具体方案<br>需纠错或补充 | 指导完整<br>仅换已说明环境值 | 指导与前提齐<br>无需补写修正 |
| 终答        | M11 综合支撑<br>连续0—100 | $M11 = 100[1 - (1 - x_1x_2x_3)(1 - x_5x_6)(1 - x_7)](0.7 + 0.3x_4)(0.9 + 0.1x_8)$<br>$x_i = M_i / 5 \ (i = 1...8)$ ；系数预定；M9/M10独立报告；未经概率校准 |                 |                 |                  |                  |

C=实际搜索+获取，失败计数；未知/受阻/N/A单列，不补零。M2完整性未知留4—5；M6高档须无未解矛盾。

# M7：把知识自评改为回答核验


## 改前 · 模型自评

自评知识强弱，再作时效修正  
不足：正确性和原题覆盖难核验



## 改后 · 回答核验

首次工具前冻结问题无工具回答  
优势：证据可追溯，自信不计分



# 同一个开发目标，分别设置两侧问题

## 1 选开发任务

覆盖环境、开发、训练、部署、优化、调试、迁移等七类工作流

## 2 确定共同目标

## 3 写成两侧问题

### 找到模型运行慢的原因

#### CUDA



GPU 利用率不高，  
怎样采集性能数据、  
找到模型运行慢的原因？

工具：Nsight Systems

交付：采集命令 + 分析步骤

#### CANN



昇腾上运行 PyTorch，  
怎样采集性能数据、  
找到模型运行慢的原因？

工具：msprof / Ascend PyTorch Profiler

交付：代码 + 步骤

目标相近，工具和交付要求按各自平台设置

25组对照问题

# 让三个模型分别完成同一组问题

25组问题，每组 CUDA / CANN 各一题

GLM-5.3

DeepSeek

V4.1 Flash

Kimi

kimi-k3-2

150

次实验

25组问题 × 2个平台 × 3个模型

同一工具

搜索 + 读取资料

同一额度

最多4次搜索 / 8次读取

同一标准

使用前页评分表

新对话

每道题重新开始

# 一次实验：先回答，再查资料，最后作答

实例：Kimi 回答 CUDA 性能分析问题



第一次回答、资料来源、最后回答、调用次数，都留下记录供评分使用

# 对照评分表打分，再回看记录复核

## 初评 · GLM-5.3

按同一张评分表评价三个被测模型的回答

实验记录

第2次搜索，  
才找到官方资料

对应评分标准

→ M1 官方发现  
第2次搜索首次找到

得分

→ 3 分

## 复核：查证据，再审定修订

程序检查

核对原文、分档与计算

→ GPT-5.6 Luna

辅助内容复核，提出修订

→ GPT-6 Astra

主代理核对并审定修订

初评与修订分别保存；复核覆盖重点内容，修改时留下依据和理由

## 各模型分别算平均，再比较结论是否一致

同一个指标下，先比较问题两侧，再汇总每个模型的任务平均



## 把共同的缺口，转成设计改进线索

更容易找到资料、更容易读取正文、更清楚的操作步骤

# 把实验方法沉淀为可复用的 Benchmark Skill

把提问、执行、记录和评分要求，整理成一套可以重复使用的方法



后续汇总：用这些产物比较平台与模型，找到设计改进线索

## 便于比较

不同平台和模型  
使用同一套规则

## 可以复核

分数能回到原始记录  
查到判断依据

## 持续复用

换任务、模型或平台  
沿用同一套流程