


知识获取流程与指标定位



概念环节定位，实际评分独立执行。模型可能无法可靠识别知识缺口；证据不足时，终答须显式说明边界。

流程各环节对应的五档评分标准


流程环节	指标	1分	2分	3分	4分	5分
搜索 候选	M1 官方发现	预算用尽 仍未发现	第3查起 首次命中	第2查 首次命中	首查 第2—5条	首查 第1条
	M5 第三方数量	0条	1—2条	3—4条	5条	至少6条
读取 正文	M2 正文取得	无可识别 目标内容	仅标题/导航 或元数据	仅明确 摘要/摘录	直接正文 缺损有据	直接正文 完整边界有据
	M3 内容支撑	只有概述	仅零散细节	完整段落 仍缺关键内容	主流程完整 仍缺分支约束	原题所需 内容全齐
模型 先验	M7 检索前知识	无正确知识 或关键主张错	只有正确概念	正确方法片段 缺关键细节	完整正确流程 缺参数约束	原题知识要求 准确全覆盖
汇总 证据	M6 说法支持	关键矛盾 尚未解决	关键说法 无核对依据	部分说法有据 其余未核验	全部说法有据 缺独立互证	全部说法有据 且独立互证
	M8 调用成本	$C \geq 9$	$C = 7-8$	$C = 5-6$	$C = 3-4$	$C = 1-2$
检查 充分性	M4 版本关系	无版本信息	无选版依据 或冲突未解	部分关系明确 缺必要对应	合并官方约束 才可确定版本	官方表/规则 直接确定版本
	M9 回答定版	缺少所需 版本信息	有版本无依据 或关键矛盾	部分组件有据 其余未定版	全部有据范围 未全定具体版	全部有据具体版 无未解冲突
	M10 操作补改	仅目标描述 或示意	仅操作骨架 关键操作不明	有具体方案 需纠错或补充	指导完整 仅换已说明环境值	指导与前提齐 无需补写修正
终答	M11 综合支撑 连续0—100	$M11 = 100[1 - (1 - x_1x_2x_3)(1 - x_5x_6)(1 - x_7)](0.7 + 0.3x_4)(0.9 + 0.1x_8)$ $x_i = M_i / 5 \ (i = 1...8)$ ；系数预定；M9/M10独立报告；未经概率校准				

C=实际搜索+获取，失败计数；未知/受阻/N/A单列，不补零。M2完整性未知留4—5；M6高档须无未解矛盾。

M7：把知识自评改为回答核验


改前 · 模型自评

自评知识强弱，再作时效修正
不足：正确性和原题覆盖难核验



改后 · 回答核验

首次工具前冻结同题无工具回答
优势：证据可追溯，自信不计分



同一个开发目标，分别设置两侧问题

1 选开发任务

覆盖环境、开发、训练、部署、优化、调试、迁移等七类工作流

2 确定共同目标

3 写成两侧问题

找到模型运行慢的原因

CUDA

GPU 利用率不高，
怎样采集性能数据、
找到模型运行慢的原因？

工具：Nsight Systems

交付：采集命令 + 分析步骤

CANN

昇腾上运行 PyTorch，
怎样采集性能数据、
找到模型运行慢的原因？

工具：msprof / Ascend PyTorch Profiler

交付：代码 + 步骤

目标相近，工具和交付要求按各自平台设置

25组对照问题

让三个模型分别完成同一组问题

25组问题，每组 CUDA / CANN 各一题

GLM-5.3

DeepSeek

V4.1 Flash

Kimi

kimi-k3-2

150 次实验

25组问题 × 2个平台 × 3个模型

同一工具

搜索 + 读取资料

同一额度

最多4次搜索 / 8次读取

同一标准

使用前页评分表

新对话

每道题重新开始

一次实验：先回答，再查资料，最后作答

实例：Kimi 回答 CUDA 性能分析问题



第一次回答、资料来源、最后回答、调用次数，都留下记录供评分使用

对照评分表打分，再回看记录复核

初评 · GLM-5.3

按同一张评分表评价三个被测模型的回答

实验记录

第2次搜索，
才找到官方资料

对应评分标准

→ M1 官方发现
第2次搜索首次找到

得分

→ 3 分

复核：查证据，再审定修订

程序检查

核对原文、分档与计算

→ GPT-5.6 Luna

辅助内容复核，提出修订

→ GPT-6 Astra

主代理核对并审定修订

初评与修订分别保存；复核覆盖重点内容，修改时留下依据和理由

各模型分别算平均，再比较结论是否一致

同一个指标下，先比较同题两侧，再汇总每个模型的任务平均



把共同的缺口，转成设计改进线索

更容易找到资料、更容易读取正文、更清楚的操作步骤

把实验方法沉淀为可复用的 Benchmark Skill

把提问、执行、记录和评分要求，整理成一套可以重复使用的方法



后续汇总：用这些产物比较平台与模型，找到设计改进线索

便于比较

不同平台和模型
使用同一套规则

可以复核

分数能回到原始记录
查到判断依据

持续复用

换任务、模型或平台
沿用同一套流程